

BÁO CÁO MILESTONE 3 – FINAL PRODUCT (VECTOR & HYBRID SEARCH)

Môn học: SEG301 – Search Engines & Information Retrieval

Nhóm: UnderFitting

Thời gian thực hiện: Tuần 8 – Tuần 10

Họ và tên	MSSV	Vai trò
Võ Minh Huy	QE190059	Leader
Thân Phúc Hậu	QE190002	Thành viên
Nguyễn Lê Anh Duy	QE190134	Thành viên

1. Tổng quan Milestone 3

Trong milestone 3, hệ thống được mở rộng từ mô hình BM25 thuần túy lên một sản phẩm hoàn chỉnh với sự kết hợp của AI và giao diện người dùng hiện đại. Các thành phần nâng cấp bao gồm:

- **Vector Search** – Tìm kiếm ngữ nghĩa qua thư viện FAISS và Sentence-Transformers.
- **Hybrid Search** – Kết hợp điểm BM25 và Vector theo phương pháp weighted fusion.
- **Web Interface** – Ứng dụng Streamlit hỗ trợ Search, Filter và Pagination.
- **Evaluation** – Đánh giá hiệu năng hệ thống trên tập 20 queries mẫu với quy mô 1.62 triệu tài liệu.

1. Kiến trúc hệ thống AI

Hệ thống được tổ chức với các module chuyên biệt hỗ trợ tìm kiếm vector và tích hợp giao diện:

<code>build_vector_index.py</code>	→ CLI build FAISS index
<code>vector_searcher.py</code>	→ Xử lý tìm kiếm ngữ nghĩa
<code>hybrid_search.py</code>	→ Thuật toán fusion BM25 + Vector
<code>app.py</code>	→ Giao diện người dùng Streamlit
<code>evaluation.py</code>	→ Đo lường Precision@10, Recall, MRR

2. Tính năng AI – Vector Search

1.1 Mô hình Embedding

Sử dụng model `intfloat/multilingual-e5-base` (768 dim). Đây là mô hình hỗ trợ tiếng Việt tốt, sử dụng cấu trúc asymmetric retrieval (query: vs passage: prefix) giúp tăng độ chính xác tìm kiếm.

1.2 FAISS Index & Tối ưu hóa bộ nhớ

Do quy mô dữ liệu lên tới 1.62 triệu tài liệu, mỗi tài liệu 4 slots vector (~20GB RAM nếu load thô), nhóm đã triển khai các kỹ thuật tối ưu:

- **IndexIVFPQ:** Nén vector giúp giảm dung lượng index xuống còn 261MB.
- **Memmap:** Đọc dữ liệu từ đĩa trực tiếp, không copy toàn bộ vào RAM.
- **Streaming Binary:** Ghi dữ liệu theo từng batch trong quá trình build index.

3. Hybrid Search Ranking

Hệ thống sử dụng công thức kết hợp điểm số để tối ưu hóa kết quả:

$$Hybrid\ Score = 0.65 \times BM25Normalized + 0.35 \times VectorNormalized$$

BM25 giữ vai trò chủ đạo (65%) để đảm bảo khớp chính xác tên riêng, mã số thuế và địa chỉ. Vector Search (35%) bổ sung khả năng tìm kiếm theo ngữ nghĩa và từ đồng nghĩa.

Quy trình:

1. Fetch `top\_k × 3` candidates từ cả BM25 và Vector (over-fetch để union đủ rộng)
2. Normalize BM25 → [0, 100]
3. Fuse: `0.65 × BM25 + 0.35 × Vector`
4. Apply hard geo-filter nếu query có địa danh
5. Sort, trả về top_k

4. Giao diện Web Streamlit

Ứng dụng web được xây dựng nhằm cung cấp trải nghiệm tìm kiếm thực tế cho người dùng:

- **Smart Filters:** Lọc theo tỉnh thành, ngành nghề và tình trạng hoạt động.
- **Geographic-Aware:** Tự động nhận diện địa danh trong query để thực hiện hard-filter

địa lý, tránh sai lệch từ embedding.

- **Score Badges:** Hiển thị rõ ràng nguồn gốc điểm số (BM25/Vector/Hybrid) cho từng kết quả.

5. Đánh giá hiệu năng (Evaluation)

Kết quả đo lường trên bộ 20 queries tiếng Việt với k=10:

Method	Precision@10	Recall@10	MRR	Avg Time (ms)
BM25	0.930	0.131	0.960	305
Vector	0.720	0.081	0.761	91
Hybrid	0.930	0.131	0.960	410

6. Phân tích

Vector nhanh hơn nhưng precision thấp hơn

Vector 91ms (FAISS IVFPQ, encode cố định) vs BM25 305ms (preprocessor + inverted index lookup). Tuy nhiên 20 queries trong bộ test chủ yếu là exact-match nên BM25 có lợi thế rõ ràng. Vector tốt hơn ở query ngữ nghĩa/tiếng Anh (**shipping logistics**) — thiếu số trong bộ test.

BM25 tốt hơn Vector khi:

- Query địa lý: **nhà hàng hà nội** — exact match token **hà_nội** mạnh hơn embedding similarity
- Tên tỉnh dễ nhầm: **bình định** vs **bình dương** — BM25 phân biệt hoàn hảo
- Query tên công ty cụ thể: exact string match hiệu quả hơn cosine similarity

Vector tốt hơn BM25 khi:

- Query tiếng Anh: **shipping logistics** → tìm được vận tải, kho vận
- Tên ngành đồng nghĩa: **CNTT** ↔ **công nghệ thông tin** ↔ **phần m ề m**

7. Ví dụ thực tế

Query ngữ nghĩa: **vận chuyển hàng hóa**

Phương pháp	Kết quả top-3 (ngành nghề)	Nhận xét
BM25	Vận tải đường bộ · Kho bãi · Giao nhận hàng hóa	Khớp chính xác từ khóa “vận chuyển”
Vector	Trung chuyển · Vận tải đường bộ · Xuất nhập khẩu	Tìm được các từ đồng nghĩa và liên quan
Hybrid	Vận tải đường bộ · Kho bãi · Trung chuyển	Kết hợp lexical + semantic, tăng recall

Query địa lý: **nhà hàng hà nội**

Phương pháp	Địa chỉ kết quả	Nhận xét
BM25	Hà Nội ✓	Exact match “hà_nội” trong inverted index
Vector	Hà Nội ✓	Cần geo-filter để loại kết quả sai
Hybrid	Hà Nội ✓	Kết hợp BM25 (65%) + geo-filter

Query đơn lẻ: **điện tử**

Phương pháp	Kết quả	Nhận xét
BM25	Linh kiện điện tử · Quang học · Thiết bị điện tử	Mở rộng theo từ khóa liên quan
Vector	Linh kiện điện tử	Matching chính xác về ngữ nghĩa
Hybrid	Linh kiện điện tử · Quang học · Thiết bị điện tử	Cân bằng precision và recall

Query tiếng Anh: **shipping logistics**

Phương pháp	Kết quả	Nhận xét
BM25	Công ty có “Shipping & Logistics” trong tên	Không xử lý tốt cross-lingual
Vector	Vận tải đường bộ · Kho vận · Giao nhận	Mapping tốt giữa Anh – Việt
Hybrid	Vận tải · Logistics	Kết hợp nhưng vẫn bias BM25

8. Kết luận Milestone 3

Hệ thống đã hoàn thiện với khả năng tìm kiếm mạnh mẽ, kết hợp giữa tốc độ của FAISS và độ chính xác của BM25. Giao diện Streamlit hoạt động ổn định, xử lý mượt mà khối lượng dữ liệu lớn của doanh nghiệp Việt Nam.