

BÁO CÁO MILESTONE 2 – SEARCH ENGINE (SPIMI & BM25)

Môn học: SEG301 – Search Engines & Information Retrieval

Nhóm: UnderFitting

Thời gian thực hiện: Tuần 5 – Tuần 7

Họ và tên	MSSV	Vai trò
Võ Minh Huy	QE190059	Leader
Thân Phúc Hậu	QE190002	Thành viên
Nguyễn Lê Anh Duy	QE190134	Thành viên

1. Tổng quan Milestone 2

Trong milestone 2, hệ thống search engine được xây dựng với mục tiêu hoàn thiện khả năng lập chỉ mục và xếp hạng tài liệu. Ba thành phần cốt lõi bao gồm:

- Indexing (Hardcore) – Cài đặt thủ công thuật toán SPIMI để xử lý dữ liệu lớn.
- Ranking (Hardcore) – Cài đặt thủ công thuật toán BM25 để tối ưu hóa kết quả tìm kiếm.
- Console Application – Ứng dụng dòng lệnh cho phép người dùng truy vấn và nhận về top 10 kết quả phù hợp nhất.


Toàn bộ hệ thống được cài đặt bằng Python, cam kết không sử dụng các thư viện hỗ trợ IR có sẵn như Whoosh, Elasticsearch hay Lucene.

2. Kiến trúc hệ thống

Hệ thống được tổ chức thành các module chuyên biệt nhằm đảm bảo tính bảo trì và mở rộng:

<code>index_builder.py</code>	→ CLI build index
<code>spimi_indexer.py</code>	→ Thuật toán SPIMI
<code>storage.py</code>	→ Lưu trữ inverted index
<code>preprocessor.py</code>	→ Tiền xử lý văn bản
<code>bm25_ranker.py</code>	→ Thuật toán BM25
<code>console_app.py</code>	→ Ứng dụng tìm kiếm dòng lệnh

3. Quy trình xử lý (Pipeline)



4. Indexing (Hardcore) – Cài đặt SPIMI

4.1 Tổng quan SPIMI

Thuật toán SPIMI (Single-Pass In-Memory Indexing) được lựa chọn để xây dựng inverted index theo từng khối (block), giúp hệ thống có thể xử lý tập dữ liệu 1.6 triệu document mà không bị tràn bộ nhớ RAM. Luồng hoạt động:

- 1. Đọc dữ liệu theo batch:** Hệ thống đọc file JSONL lần lượt, gom từng 1000 tài liệu thành một batch để xử lý
- 2. Tiền xử lý & tính TF:** Mỗi batch được tokenize, loại bỏ stopwords, đếm tần suất từng term (TF) trong document

- 3. Xây dựng inverted index trong RAM:** Dữ liệu được lưu dưới dạng inverted index (term → danh sách doc_id và tần suất)
- 4. Giám sát bộ nhớ:** Hệ thống liên tục theo dõi mức bộ nhớ sử dụng (target: 500MB/block)
- 5. Ghi block xuống disk:** Khi vượt quá 500MB, index hiện tại được ghi thành block tạm, sau đó reset để xử lý batch tiếp theo
- 6. Merge blocks:** Sau khi xử lý hết file, tất cả blocks được gộp lại, postings được sắp xếp lại theo doc_id
- 7. Lưu chỉ mục cuối:**
- postings.bin:** Binary file chứa postings (doc_id, tần suất) cho mỗi term.
 - terms.pkl:** Mapping term → vị trí trong postings.bin.
 - doc_info.pkl:** Metadata mỗi document (độ dài, nội dung gốc).
 - metadata.json:** Thống kê toàn corpus (tổng docs, terms).

4.2 Cấu trúc dữ liệu Index

Inverted index được tổ chức dưới dạng từ điển: mỗi term ánh xạ tới danh sách các posting (doc_id, term_frequency). Ví dụ:

điện_lực → [(doc_1, 2), (doc_5, 1), (doc_7, 3), ...]
dệt_may → [(doc_2, 1), (doc_8, 2), ...]

5. Text Preprocessing

5.1. Pipeline xử lý văn bản:

5.1.1 Chuẩn hóa Unicode tiếng Việt & Lowercase.

- Sử dụng NFC (Composed Form) để giữ nguyên các dấu tiếng Việt (á, à, â, ã, ạ, ã, ...).
- Chuyển tất cả về chữ thường để đồng nhất.
- Lý do chọn NFC thay vì NFKD là vì NFKD có thể tách dấu tiếng Việt thành các combining marks, làm hỏng các từ như "công_nghệ".

5.1.2. Tokenization & Xử lý Ký tự Đặc biệt:

- Văn bản được tách thành các từ (tokens) bằng khoảng trắng.
- Loại bỏ các ký tự đặc biệt (@, #, \$, ...) nhưng giữ lại toàn bộ các ký tự tiếng Việt có dấu.

5.1.3. Phrase Segmentation:

- Chuyển các cụm từ tiếng Việt thành single token.
- Hệ thống duy trì một danh sách ~25 cụm từ công nghiệp (dệt may, điện lực, công nghệ thông tin, v.v.) và sử dụng thuật toán "longest matching" để phát hiện chúng. Ví dụ:

Input: ["công", "ngành", "dệt", "may", "tại", "TP", "HCM"]

Output: ["công", "ngành", "dệt_may", "tại", "tp", "hcm"]

- Các phrase được lưu dưới dạng underscore (dệt_may) để sau này có thể tùy chọn match với cả hai hình thức "dệt_may" hoặc "dệt may".

5.1.4. Loại bỏ Stopwords:

Danh sách bao gồm ~40 từ tiếng Việt: và, để, là, của, do, được, tại, từ, vào, với, có, cái, cần, các, như, thì, hoặc, nhưng, v.v. Đồng thời loại bỏ các từ dài dưới 2 ký tự.

5.2 Query Processing & Intent Detection

Khi người dùng nhập query, hệ thống không chỉ tokenize mà còn:

- **Phát hiện Intent Group:** Kiểm tra xem query chứa các từ khóa từ nhóm intent nào (electric_power, electronics, technology, food_service, v.v.). Ví dụ:
 - Query "điện lực công ty" → activate 'electric_power' group
 - Query "công ty điện tử" → activate 'electronics' group
- **Mở rộng Query (Query Expansion):** Dựa trên intent group được phát hiện, hệ thống mở rộng query bằng các từ đồng nghĩa tiếng Việt. Ví dụ:
 - "electric" → thêm ["điện_lực", "điện_năng", "phát_điện", "truyền_tải_điện", "phân_phối_điện"]
 - "technology" → thêm ["công_nghệ_thông_tin", "phần_mềm", "dữ_liệu_lớn"]
 - "food" → thêm ["thực_phẩm", "ăn_uống", "dịch_vụ_ăn_uống", "nhà_hàng", "quán_ăn"]
- **Tách Intent Terms:** Các từ "intent" (từ khóa domain-specific) được tách riêng từ các generic terms như "công ty", "doanh nghiệp".

6. Ranking (Hardcore) – Cài đặt BM25

6.1 BM25 Formula

Thuật toán xếp hạng BM25 được code thủ công dựa trên công thức chuẩn:

$$BM25 = IDF \times \frac{tf(k1 + 1)}{tf + k1 (1 - b + b \frac{dl}{avgdl})}$$

Các thành phần chính:

- **IDF (Inverse Document Frequency):** Tính toán độ hiếm của từ khóa trên toàn bộ kho dữ liệu.
- **Doc Length Normalization:** Điều chỉnh điểm số dựa trên độ dài của văn bản (dl) so với độ dài trung bình (avgdl).
- **Saturating TF:** Sử dụng tham số k1 để kiểm soát mức độ ảnh hưởng của tần suất từ khóa.

6.2 Chi tiết cài đặt BM25

- Khởi tạo BM25 Ranker.
- Tính toán IDF.
- Tính toán BM25 Score cho một term.

6.3 Intent-Aware Filtering & Boosting

- **Column-aware Intent Rules:** Hệ thống định nghĩa rules cho từng intent group để tránh nhầm lẫn giữa các domains gần nhau.
- Khi strict intent filtering được bật, hệ thống kiểm tra "Ngành nghề kinh doanh" field của document:

- Phải chứa ít nhất một positive term của intent group
- Không được chứa bất kỳ negative term nào

Cách làm này giúp loại bỏ kết quả không liên quan.

- Keyword Boosting: Ngoài BM25 base score, hệ thống áp dụng thêm các bonus:
 - Exact phrase matching: Nếu query nguyên vẹn xuất hiện trong các fields:
 - Tên doanh nghiệp $\rightarrow +3.0$
 - Tên giao dịch $\rightarrow +2.5$
 - Ngành nghề $\rightarrow +1.5$
 - Per-term field-aware boost: Cho mỗi term trong query, kiểm tra xem nó có xuất hiện trong các fields không:
 - Xuất hiện trong field $\rightarrow +0.25 \times \text{field_weight}$
 - Xuất hiện và term có dấu gạch dưới (phrase) $\rightarrow +0.35 \times \text{field_weight}$

6.4 Full Ranking Pipeline

Quy trình xếp hạng hoàn chỉnh bao gồm các bước:

1. Collected Candidates.
2. Strict Intent Filtering (optional).

3. Intent Group Filtering (optional).
4. Coverage Bonus.
5. Intent Boost.
6. Group-level Boost.
7. Reranking with Keyword Boost.
8. Final Top-K Selection.

7. Console Application

Ứng dụng dòng lệnh cho phép tương tác trực tiếp: nhập truy vấn và hiển thị 10 kết quả tốt nhất.
Ví dụ kết quả:

➤ search may mặc

🔍 Searching for: may mặc

Query terms: may_mặc, phụ_liệu_may_mặc, dệt_may

Intent terms (strict): may_mặc, phụ_liệu_may_mặc, dệt_may

Intent group: textile

Found 10 results in 4116.87ms

📄 Rank 1

Score: 28.4416

Company: CÔNG TY TNHH PHỤ LIỆU MAY MẶC HỒNG VIỆT

Tax ID: 312742705

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: 47/2 ấp 2, Xã Nhị Bình, Huyện Hóc Môn, TP Hồ Chí Minh

Status: Doanh nghiệp tạm dừng hoạt động hoặc đã ngừng hoạt động từ ngày 23/11/2018

📄 Rank 2

Score: 27.5405

Company: CÔNG TY CỔ PHẦN PHỤ LIỆU MAY MẶC TOÀN CẦU

Tax ID: 0317312752

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: Số 4 Đường Bến Nghé, Phường Tân Thuận Đông, Quận 7, TP Hồ Ch...

Status: Đang hoạt động (đã được cấp GCN ĐKT)

 Rank 3

Score: 27.5405

Company: CÔNG TY TNHH PHỤ LIỆU MAY MẶC SANG MINH

Tax ID: 0318519710

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: 20 Minh Phụng, Phường 05, Quận 6, TP Hồ Chí Minh

Status: Đang hoạt động (đã được cấp GCN ĐKT)

 Rank 4

Score: 27.3314

Company: CÔNG TY TNHH THƯƠNG MẠI DỊCH VỤ PHỤ LIỆU MAY MẶC TUẤN ANH

Tax ID: 0317176299

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: 2/275 ấp Đồng Hòa, Xã Long Hoà, Huyện Cần Giờ, TP Hồ Chí Min...

Status: Đang hoạt động (đã được cấp GCN ĐKT)

 Rank 5

Score: 27.3314

Company: CÔNG TY TNHH THƯƠNG MẠI MÁY MÓC VÀ PHỤ LIỆU MAY MẶC LIÊN HOA

Tax ID: 0318100976

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: 278 Nguyễn Đình Chiểu, Phường Võ Thị Sáu, Quận 3, TP Hồ Chí ...

Status: Đang hoạt động (đã được cấp GCN ĐKT)

 Rank 6

Score: 26.3696

Company: CÔNG TY TNHH PHỤ LIỆU MAY MẶC THỊNH PHÁT

Tax ID: 312629675

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: 99 A Đường Phạm Văn Sáng, Xã Xuân Thới Thượng, Huyện Hóc Môn...

Status: Đang hoạt động (đã được cấp GCN ĐKT)

 Rank 7

Score: 25.6466

Company: CÔNG TY TNHH DỆT MAY MẶC TUẤN KHANH

Tax ID: 0317761370

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: 10 Sông Thao, Phường 2, Quận Tân Bình, TP Hồ Chí Minh

Status: Đang hoạt động (đã được cấp GCN ĐKT)

 Rank 8

Score: 25.5128

Company: CÔNG TY TNHH MAY MẶC VÀ DỆT MAY EST

Tax ID: 0106700636

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: Phòng 1003, tầng 10, Chung cư dầu khí, số 458, đường Lý Bôn,...

Status: Doanh nghiệp tạm dừng hoạt động hoặc đã ngừng hoạt động từ ngày 09/10/2019

 Rank 9

Score: 24.7366

Company: CÔNG TY TNHH DỆT MAY MẶC NASI

Tax ID: 0317300549

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: Số 07 Đường Số 04, Cityland Park Hills, Phường 10, Quận Gò V...

Status: Đang hoạt động (đã được cấp GCN ĐKT)

 Rank 10

Score: 24.1456

Company: CÔNG TY TNHH TM KINH DOANH DỆT MAY LÊ TÙNG

Tax ID: 0317932499

Industry: Bán buôn vải, hàng may mặc, giày dép

Address: Số H 4 C Bạch Mã, Phường 15, Quận 10, TP Hồ Chí Minh

Status: Đang hoạt động (đã được cấp GCN ĐKT)

8. Kết luận Milestone 2

Milestone 2 hoàn thành cài đặt thủ công hai thuật toán IR cốt lõi:

1. SPIMI (Single-Pass In-Memory Indexing)

- Xử lý 1.6M documents với memory constraint (500MB/block).
- Efficient block merging theo sorted postings.
- Binary storage format cho compact index.

2. BM25 Ranking Algorithm

- Chấm điểm độ liên quan dựa trên xác suất.
- Tăng cường trường cho việc khớp cụm từ chính xác.
- Lọc nhận biết ý định để phân biệt các tên miền gần nhau.
- Thưởng độ phủ cho các truy vấn nhiều từ khóa.
- Bộ nhớ đệm IDF + bộ nhớ đệm kết quả truy vấn để cải thiện hiệu suất.

3. NLP Pipeline Tiếng Việt

- Phrase segmentation (dệt_may, điện_lực, công_nghệ_thông_tin).
- Intent detection (8+ nhóm intent).
- Mở rộng truy vấn (Tiếng Anh ↔ Tiếng Việt).
- Loại bỏ Stopwords (40+ từ Tiếng Việt).

4. Interactive Console Application

- Xử lý truy vấn thời gian thực.
- Top 10 kết quả với thông tin chi tiết.
- Score explanation.

