

BÁO CÁO MILESTONE 3 – FINAL PRODUCT (VECTOR & HYBRID SEARCH)

Môn học: SEG301 – Search Engines & Information Retrieval

Nhóm: UnderFitting

Thời gian thực hiện: Tuần 8 – Tuần 10

Họ và tên	MSSV	Vai trò
Võ Minh Huy	QE190059	Leader
Thân Phúc Hậu	QE190002	Thành viên
Nguyễn Lê Anh Duy	QE190134	Thành viên

1. Tổng quan Milestone 3

Milestone 2 đã xây dựng hệ thống tìm kiếm dựa trên BM25 + SPIMI inverted index với corpus 1,620,401 tài liệu doanh nghiệp Việt Nam. Milestone 3 nâng cấp lên sản phẩm hoàn chỉnh bằng cách bổ sung ba thành phần chính:

Thành phần	Mô tả
Vector Search	Tìm kiếm ngữ nghĩa qua FAISS + Sentence-Transformers
Hybrid Search	Kết hợp điểm BM25 và Vector theo weighted fusion
Web Interface	Ứng dụng Streamlit hỗ trợ Search, Filter, Pagination
Evaluation	Đánh giá Precision@10, Recall@10, MRR trên 20 queries

Dữ liệu: 1,620,401 tài liệu công ty Việt Nam (định dạng JSONL). Các trường chính: Tên doanh nghiệp, Tên giao dịch, Ngành nghề kinh doanh, Địa chỉ, Tình trạng hoạt động.

2. Tính năng AI – Vector Search

2.1. Mô hình Embedding

Thuộc tính	Chi tiết
Model	intfloat/multilingual-e5-base
Kiến trúc	Transformer (BERT-based), 12 layers, 768-dim
Ngôn ngữ	100+ ngôn ngữ, hỗ trợ tiếng Việt

Device	CUDA (GPU RTX 3050) + CPU fallback
FP16	Tùy chọn (--fp16), $\sim 2\times$ tốc độ encode

Sử dụng model **intfloat/multilingual-e5-base** (768 dim). Đây là mô hình hỗ trợ tiếng Việt tốt, sử dụng cấu trúc asymmetric retrieval (query: vs passage: prefix) giúp tăng độ chính xác tìm kiếm.

2.2 Embedding đa trường

Mỗi tài liệu được embed thành 4 vector riêng biệt, lưu ở 4 FAISS slots liên tiếp:

Slot	Trường	Mục đích
0	Tên doanh nghiệp + Tên giao dịch	Truy vấn theo tên công ty cụ thể
1	Ngành nghề kinh doanh	Truy vấn theo lĩnh vực hoạt động
2	Tỉnh/thành (trích từ cuối địa chỉ)	Truy vấn theo vị trí địa lý
3	Full-doc (name + industry + province)	Truy vấn kết hợp nhiều tiêu chí

2.3. FAISS Index và tối ưu RAM khi build index

Tham số	Giá trị	Giải thích
Index type	IndexIVFPQ	Inverted File + Product Quantization
Metric	Inner Product	Cosine similarity (L2-normalized)
nlist	256	Số clusters (Voronoi cells)
M (sub-quantizers)	32	$768/32 = 24$ bytes/code
nprobe	32	Số clusters tìm khi search (12.5%)
Kích thước	261 MB	Giảm $\sim 20\times$ so với IndexFlatIP (~ 5 GB)

Do quy mô dữ liệu lên tới 1.62 triệu tài liệu, mỗi tài liệu 4 slots vector (~ 20 GB RAM nếu load thô), nhóm đã triển khai các kỹ thuật tối ưu:

- **Streaming binary:** Mỗi batch ghi xuống đĩa ngay sau encode, không tích lũy RAM.
- **Memmap IO:** Đọc file binary qua memory-mapped IO.
- **Producer-Consumer threading:** Thread đọc JSONL song song với GPU encode.
- **Checkpoint/Resume:** Lưu state mỗi 5,000 docs, tự tiếp tục nếu bị ngắt.

→ **RAM thực tế:** ~ 6 MB thay vì 20 GB.

3. Hybrid Search Ranking

3.1 Công thức:

Hệ thống sử dụng công thức kết hợp điểm số để tối ưu hóa kết quả:

$$Hybrid\ Score = 0.65 \times BM25Normalized + 0.35 \times VectorNormalized$$

BM25 giữ vai trò chủ đạo (65%) để đảm bảo khớp chính xác tên riêng, mã số thuế và địa chỉ. Vector Search (35%) bổ sung khả năng tìm kiếm theo ngữ nghĩa và từ đồng nghĩa.

3.2. Quy trình:

1. Fetch $top_k \times 3$ candidates từ cả BM25 và Vector (over-fetch để union đủ rộng).
2. Normalize BM25 $\rightarrow [0, 100]$ theo max score.
3. Fuse: $0.65 \times BM25 + 0.35 \times Vector$.
4. Apply hard geo-filter nếu query có địa danh.
5. Sort và trả về top_k.

3.3 Điểm mạnh bù trừ của BM25 và Vector

Khía cạnh	BM25	Vector
Exact keyword match	Rất tốt	Trung bình
Đồng nghĩa / paraphrase	Kém	Tốt
Cross-lingual (Anh-Việt)	Không hỗ trợ	Tốt
Phân biệt tính tương tự	Hoàn hảo	Kém (cần geo-filter)
Tốc độ	~300ms	~90ms

4. Giao diện Web Streamlit

4.1. Tính năng chính

Tính năng	Chi tiết
Search	3 phương pháp: BM25 / Vector / Hybrid
Filter	Tỉnh trạng, tỉnh/thành, ngành nghề — auto re-search khi thay đổi
Pagination	10 kết quả/trang, điều hướng ◀ / ▶
Stats bar	Tổng kết quả, sau bộ lọc, thời gian (ms), phương pháp

Score badge	Màu: BM25 (cam) / Vector (xanh lá) / Hybrid (xanh dương)
Sub-scores	Hybrid mode hiển thị BM25, Vector, Hybrid score từng kết quả
Caching	@st.cache_resource — index load 1 lần, tái dùng toàn session

4.2 Smart Filter & Re-search

Filter tỉnh/thành và ngành nghề không chỉ là post-filter mà còn incorporate vào query để re-search. Ví dụ: user gõ filter "hà nội" → effective_query = "điện tử hà nội" → search engine tìm đúng vùng từ đầu.

Bộ lọc	Loại	Cơ chế
Tình trạng	Post-filter	Lọc trên kết quả đã có
Tỉnh/Thành	Re-search trigger	Thêm địa danh vào query + geo hard-filter
Ngành nghề	Re-search trigger	Kích hoạt re-search mới

5. Đánh giá hiệu năng (Evaluation)

5.1. Phương pháp

- **20 queries** tiếng Việt, cover đa ngành: công nghệ, F&B, xây dựng, logistics, y tế, giáo dục, năng lượng,...
- **Pooling:** Mỗi query chạy cả 3 methods, lấy top-50 mỗi method. Union tạo pool ~100-150 docs/query.
- **Relevance judgment:** Tự động — doc relevant nếu chứa ≥ 1 keyword trong Tên/Ngành nghề/Tên giao dịch.

5.2. Kết quả:

‘Kết quả đo lường trên bộ 20 queries tiếng Việt với k=10:

Method	Precision@10	Recall@10	MRR	Avg Time (ms)
BM25	0.930	0.131	0.960	305
Vector	0.720	0.081	0.761	91
Hybrid	0.930	0.131	0.960	410

5.3. Hiệu năng hệ thống:

Thao tác	Thời gian
BM25 search (top 50)	~300ms
Vector search (top 50)	~90ms
Hybrid search (top 50)	~400ms
Build BM25 index	~10–15 phút
Build Vector index (GPU)	~5 giờ
Load hệ thống (lần đầu / cache)	~5s / <1ms

Component	Dung lượng
Inverted index (BM25)	404 MB
FAISS IVFPQ index	261 MB
Metadata + offsets	~25 MB
Tổng	~720 MB

6. Phân tích kết quả:

6.1. Vector nhanh hơn nhưng precision thấp hơn

Vector 91ms (FAISS IVFPQ, encode cố định) vs BM25 305ms (preprocessor + inverted index lookup). Tuy nhiên 20 queries trong bộ test chủ yếu là exact-match nên BM25 có lợi thế rõ ràng. Vector tốt hơn ở query ngữ nghĩa/tiếng Anh (**shipping logistics**) — thiếu số trong bộ test.

6.2. BM25 tốt hơn Vector khi:

- Query địa lý: **nhà hàng hà nội** — exact match token **hà_nội** mạnh hơn embedding similarity
- Tên tỉnh dễ nhầm: **bình định** vs **bình dương** — BM25 phân biệt hoàn hảo
- Query tên công ty cụ thể: exact string match hiệu quả hơn cosine similarity

6.3. Vector tốt hơn BM25 khi:

- Query tiếng Anh: **shipping logistics** → tìm được vận tải, kho vận
- Tên ngành đồng nghĩa: **CNTT** ↔ **công nghệ thông tin** ↔ **phần mềm**

7. Ví dụ thực tế

Query ngữ nghĩa: vận chuyển hàng hóa:

Phương pháp	Kết quả top-3 (ngành nghề)	Nhận xét
BM25	Vận tải đường bộ · Kho bãi · Giao nhận hàng hóa	Khớp chính xác từ khóa “vận chuyển”
Vector	Trung chuyển · Vận tải đường bộ · Xuất nhập khẩu	Tìm được các từ đồng nghĩa và liên quan
Hybrid	Vận tải đường bộ · Kho bãi · Trung chuyển	Kết hợp lexical + semantic, tăng recall

Query địa lý: nhà hàng hà nội

Phương pháp	Địa chỉ kết quả	Nhận xét
BM25	Hà Nội ✓	Exact match “hà_nội” trong inverted index
Vector	Hà Nội ✓	Cần geo-filter để loại kết quả sai
Hybrid	Hà Nội ✓	Kết hợp BM25 (65%) + geo-filter

Query đơn lẻ: điện tử

Phương pháp	Kết quả	Nhận xét
BM25	Linh kiện điện tử · Quang học · Thiết bị điện tử	Mở rộng theo từ khóa liên quan
Vector	Linh kiện điện tử	Matching chính xác về ngữ nghĩa
Hybrid	Linh kiện điện tử · Quang học · Thiết bị điện tử	Cân bằng precision và recall

Query tiếng Anh: shipping logistics

Phương pháp	Kết quả	Nhận xét
BM25	Công ty có “Shipping &	Không xử lý tốt cross-lingual

	Logistics” trong tên	
Vector	Vận tải đường bộ · Kho vận · Giao nhận	Mapping tốt giữa Anh – Việt
Hybrid	Vận tải · Logistics	Kết hợp nhưng vẫn bias BM25

8. Kết luận Milestone 3

Hệ thống đã hoàn thiện với khả năng tìm kiếm mạnh mẽ, kết hợp giữa tốc độ của FAISS và độ chính xác của BM25. Giao diện Streamlit hoạt động ổn định, xử lý mượt mà 1.62 triệu tài liệu doanh nghiệp Việt Nam.

Điểm nổi bật:

- **Vector Search:** FAISS + multilingual-e5-base, 4 slots/doc, tối ưu RAM ~6MB khi build.
- **Hybrid Search:** BM25 (65%) + Vector (35%) với geo-filter, xử lý tốt exact match lẫn semantic query.
- **Web Interface:** Streamlit với Smart Filter, Geographic-Aware BM25, Pagination, Score badges.
- **Evaluation:** $P@10 = 0.93$, $MRR = 0.96$ (BM25/Hybrid). Vector tốt hơn ở cross-lingual và semantic.