

BÁO CÁO MILESTONE 1 – DATA ACQUISITION

Môn học: SEG301 – Search Engines & Information Retrieval

Nhóm: UnderFitting

Thời gian thực hiện: Tuần 1 – Tuần 4

Họ và tên	MSSV	Vai trò
Võ Minh Huy	QE190059	Leader
Thân Phúc Hậu	QE190002	Thành viên
Nguyễn Lê Anh Duy	QE190134	Thành viên

1. Tổng quan Milestone 1

Milestone 1 tập trung vào giai đoạn **Data Acquisition**, với mục tiêu xây dựng một **bộ dữ liệu lớn (Big Data) tối thiểu 1.000.000 document**, được thu thập, làm sạch và lưu trữ theo định dạng có cấu trúc, làm nền tảng cho các giai đoạn Indexing, Ranking và Search Engine sau này.

Nhóm đã triển khai **pipeline hoàn chỉnh** gồm:

- Thu thập dữ liệu (Crawling)
- Làm sạch & tiền xử lý (Data Cleaning & Preprocessing)
- Loại bỏ trùng lặp (De-duplication)
- Lưu trữ dữ liệu có cấu trúc (Structured Storage)
- Thống kê & phân tích dữ liệu (Data Insight)

2. Kết quả đạt được

2.1. Khối lượng dữ liệu

- Số lượng document sau xử lý: 1.620.401
- Mục tiêu yêu cầu: $\geq 1.000.000$

Tỷ lệ hoàn thành so với mục tiêu:

$$\frac{1.620.401}{1.000.000} \times 100\% = 162,04\%$$

Nhóm đã vượt mục tiêu 62.04% so với yêu cầu tối thiểu.

2.1. Tổng quan dữ liệu

Dữ liệu gồm 11 cột:

- Tên doanh nghiệp
- Tên giao dịch
- Mã số thuế
- Địa chỉ
- Tình trạng hoạt động
- Ngày cấp giấy phép
- Cơ quan thuế
- Phương pháp tính thuế
- Ngành nghề kinh doanh
- Chương khoản
- Review (nếu có)

Ví dụ 1 document:

```
{"Tên doanh nghiệp": "CÔNG TY CỔ PHẦN BLISS", "Tên giao dịch": "BLISS CORP", "Mã số thuế": "0314571999", "Địa chỉ": "P 709 Tầng 7, tòa nhà Hoàng Anh Gia Lai, số 7/1, đường Thành, Phường 14, Quận 10, TP Hồ Chí Minh", "Tình trạng hoạt động": "Đang hoạt động (đã được cấp GCN ĐKT)", "Ngày cấp giấy phép": "14/08/2017", "Cơ quan thuế": "", "Phương pháp tính thuế": "", "Ngành nghề kinh doanh": "Quảng cáo", "Chương khoản": "", "reviews": [{"rating": "5.0", "role": "Nhân viên hiện tại", "title": "Văn hoá công ty tuyệt vời giúp phát
```

```
triển nghề nghiệp và cuộc sống", "meta": "Nhân viên - Hồ Chí Minh - 04/10/2024", "pros": "Công ty có một văn hoá tuyệt vời, luôn tạo ra môi trường thân thiện và hỗ trợ nhân viên phát triển toàn diện, không chỉ trong sự nghiệp mà còn trong cuộc sống cá nhân. Sếp rất tận tâm và luôn sẵn sàng chia sẻ kiến thức, đồng nghiệp thì vui vẻ, dễ gần, tạo cảm giác làm việc như trong một gia đình. Điều này giúp nhân viên có động lực để cống hiến và phát triển nghề nghiệp một cách tốt nhất.", "cons": "Không có nhược điểm nào về lương, phúc lợi, chế độ làm việc, môi trường làm việc, văn hóa công ty... được đề cập trong reviews này."}}}
```

3. Quy trình thu thập dữ liệu (Crawling)

3.1. Công nghệ sử dụng

- **Ngôn ngữ:** Python
- **Thư viện chính:**
 - `requests`, `aiohttp` – HTTP requests
 - `asyncio` – xử lý bất đồng bộ (Async)

3.2. Kỹ thuật crawl

- Áp dụng **Asynchronous Crawling** để:
 - Tăng tốc độ thu thập dữ liệu
 - Giảm thời gian chờ I/O
- Cơ chế tăng tốc crawl:
 - Sử dụng nhiều worker (50) để xử lý song song
- Cơ chế crawl:
 - Crawl trang web chính, lấy list đường link trang cụ thể bỏ vào QUEUE
 - Lấy link trang trong QUEUE, crawl trang web lấy thông tin cụ thể, ghi vào BUFFER
 - Ghi dữ liệu theo BATCH, không ghi từng document.

- Mỗi 2 giây, nếu số lượng document trong BUFFER $\geq$ BATCH_SIZE thì sẽ ghi vào file, tránh mở file nhiều lần
- Cơ chế xử lý page đang crawl:
 - Ghi ra màn hình log của trang đang crawl
 - Code có START_PAGE và END_PAGE
 - Khi resume nhìn vào log và sửa lại START_PAGE và END_PAGE

Đảm bảo **tính ổn định và khả năng mở rộng** khi xử lý dữ liệu lớn.

4. Xử lý dữ liệu sau khi Crawl (Data Processing Pipeline)

Sau khi crawl thô, dữ liệu được đưa qua pipeline xử lý gồm các bước sau:

4.1. Làm sạch dữ liệu (Cleaning)

- Loại bỏ:
 - Thẻ HTML
 - Script, CSS
 - Ký tự đặc biệt không cần thiết ♦
- Chuẩn hóa encoding UTF-8-sig.
- Loại bỏ dữ liệu lỗi font, dữ liệu rỗng:
 - Lỗi font: Tên đường, địa chỉ có chữ và số bị dán vào nhau
 - Dữ liệu rỗng: Chuẩn hóa thành “” thay vì NaN

4.2. Xử lý trùng lặp (De-duplication)

- Áp dụng các kỹ thuật:
 - Chuẩn hóa văn bản (lowercase, remove punctuation)
 - So khớp chuỗi (string similarity)
- Loại bỏ document trùng hoàn toàn bằng cách so khớp kết hợp 2 cột Tên doanh nghiệp và Mã số thuế

Giảm nhiễu dữ liệu, nâng cao chất lượng tập huấn luyện.

4.3. Chuẩn hóa & hợp nhất dữ liệu (Normalization & Merging)

- Chuẩn hóa tên, nội dung văn bản.
- Áp dụng:
 - So khớp chuỗi mờ (Fuzzy Matching)
 - Semantic Matching (Sentence Embedding – Multilingual)
- Hợp nhất thông tin liên quan vào cùng document.
- Ghi log quá trình ghép để đảm bảo khả năng audit.

5. Lưu trữ dữ liệu (Storage)

- Định dạng:
 - **JSONL** (mỗi dòng là một document JSON)
- Lý do lựa chọn:
 - Phù hợp với dữ liệu lớn
 - Dễ stream khi indexing
 - Không tạo 1.000.000 file rời rạc

6. Thống kê & Insight dữ liệu

Sau khi hoàn tất tiền xử lý:

- **Tổng số document:** 1.620.401 Document
- **Độ dài trung bình document:** 81,45 Token
- **Số lượng từ vựng (Vocabulary size):** 1.688.794 Từ
- **Dữ liệu sạch:**
 - Không HTML
 - Không lỗi font

Dữ liệu sẵn sàng cho **Indexing (SPIMI)** ở Milestone 2.

7. GitHub & AI Logging

- Commit code **xuyên suốt từ tuần 1**
- Không có hiện tượng “code xong rồi upload một lần”
- Có file [ai_log.md](#):
 - Lưu toàn bộ lịch sử làm việc với AI
 - Mapping rõ ràng giữa:
 - Câu hỏi AI
 - Đoạn code / giải pháp tương ứng

8. Kết luận

Nhóm đã hoàn thành Milestone 1 với:

- Khối lượng dữ liệu vượt yêu cầu **62,04%**
- Pipeline xử lý dữ liệu bài bản, đúng chuẩn IR
- Dữ liệu sẵn sàng cho các giai đoạn Indexing & Ranking tiếp theo

Milestone này tạo nền móng vững chắc cho việc xây dựng **Vertical Search Engine** trong các milestone sau.